


$$Y_{n,d} = \frac{X_{n,d} - \mu_n}{\sqrt{v_n + \epsilon}} \gamma_d + \beta_d$$

$$\mu_n = \frac{1}{D} \sum_d X_{n,d}, \quad v_n = \frac{1}{D} \sum_d (X_{n,d} - \mu_n)^2$$


LayerNorm: 沿 D 归约, 每个 token 独立



$$Y_{n,d} = \frac{X_{n,d}}{\sqrt{q_n + \epsilon}} \gamma_d$$

$$q_n = \frac{1}{D} \sum_d X_{n,d}^2$$

RMSNorm: 沿 D 归约, 每个 token 独立



维度 B : 批大小; T : 序列长度; D : 特征维。将 $B \times T \times D$ 展开为 $N \times D$, $N = BT$; 每行对应一个 (b, t) 。

对象 X, Y 为实数张量; 橙色列是每行一个标量的统计量。 $\gamma, \beta \in \mathbb{R}^D$ 在所有 token 行间共享。

机制 实线表示计算依赖或输入复用, 虚线表示本行统计量沿 D 广播; 输出恢复为 $B \times T \times D$ 。格子仅示意轴结构。