


$$O_h = \text{softmax}\left(Q_h K_{g(h)}^\top / \sqrt{d} + M\right) V_{g(h)}$$

$$g(h) = \lfloor h / (H_q / H_{kv}) \rfloor, \quad C_{KV} = 2B T_{kv} H_{kv} d s$$

MHA $H_q = 4, H_{kv} = 4$

每个 Q 头使用独立的 K/V




$$Q: B \times 4 \times T_q \times d$$

$$K, V: B \times 4 \times T_{kv} \times d$$

KV 缓存: C_{MHA}

GQA $H_q = 4, H_{kv} = 2$

每两个 Q 头共享一组 K/V




$$Q: B \times 4 \times T_q \times d$$

$$K, V: B \times 2 \times T_{kv} \times d$$

KV 缓存: $\frac{1}{2} C_{\text{MHA}}$

MQA $H_q = 4, H_{kv} = 1$

全部 Q 头共享一组 K/V



$$Q: B \times 4 \times T_q \times d$$

$$K, V: B \times 1 \times T_{kv} \times d$$

KV 缓存: $\frac{1}{4} C_{\text{MHA}}$

维度 B : 批量; T_q/T_{kv} : 查询/缓存长度; d : 每头维度; H_q/H_{kv} : Q/KV 头数; s : 每元素字节数。

对象 方块为单个 batch 的浮点头张量; 蓝色 Q、橙色 K、紫色 V。 $h \in \{0, \dots, H_q - 1\}$, $g(h)$ 是 KV 头编号; M 为加性 mask。

机制 连线表示“使用这组 K/V”，不表示 Q 生成 K/V; 共享发生在头轴, Q 头数与输出头数保持不变。缓存比例仅计单层 K 与 V, 相同 B, T_{kv}, d, s , 不计额外存储开销。