


$$P = \text{softmax}_j \left(QK^\top / \sqrt{d} + M \right), \quad O = PV$$

$$M_{ij} = \begin{cases} 0, & A_{ij} = 1 \\ -\infty, & A_{ij} = 0 \end{cases} \quad A_{ij} \in \{0, 1\}$$

完整因果

访问自身与全部历史

Key 位置 $j \rightarrow$



A^{causal}


$N \times N \quad (N = 10)$

$$j \leq i$$

因果滑动

$w = 3$: 自身与前两个位置

Key 位置 $j \rightarrow$



A^{window}


$N \times N \quad (N = 10)$

$$0 \leq i - j < w$$

局部+全局 token

因果稀疏示例: $G = \{0, 5\}$

Key 位置 $j \rightarrow$



A^{sparse}

$N \times N \quad (N = 10)$

$$j \leq i \text{ 且}$$

$$i - j < w \vee i \in G \vee j \in G$$

维度

单个 batch、单个头；行是 Query i ，列是 Key j ， $i, j \in \{0, \dots, N - 1\}$ 。 w 含当前位置， d 为每头维度。

对象

A 是布尔可见性矩阵， M 是加性 mask， P 是逐行归一化的概率。蓝色为允许连接；橙色为全局 token 新增连接；白色为屏蔽。

机制

三种模式均不访问未来。右图中，全局 Query 可访问全部历史，后续 Query 可访问全局 Key；这是自定义因果示例。颜色表示连接存在，不表示注意力权重。