



$$\tilde{q}_{t,h} = q_{t,h}^C (U_h^K)^\top, \quad p_{t,h} = \text{softmax}_j \left(\frac{\tilde{q}_{t,h} C^\top + q_{t,h}^R (K^R)^\top}{\sqrt{d_c + d_R}} \right)$$

$$z_{t,h} = p_{t,h} C, \quad o_{t,h} = z_{t,h} U_h^V$$

1 内容与位置分数相加，再沿历史位置归一化



2 复用同一份 latent 缓存，先聚合再做 Value 投影



维度 单个 batch、当前 token t 、单个头 h ； T 为截至当前的有效缓存长度， r 为 latent 宽度， $d_c/d_R/d_v$ 为内容 key、RoPE、value 维度。

对象 橙色 C 与紫色 K^R 是跨头共享的浮点缓存；蓝色是当前 query、中间量或输出， p 是概率；灰色是学习到的投影权重。

机制 C 与 $C^\top$ 为同一缓存的不同视图，转置交换图面高宽；两份缓存每 token 合计 $r + d_R$ 个元素。图示边长编码轴身份，不代表实际维度比例。