


$$M_{\text{card}} = 10sbh + \frac{24sbh}{t} + \frac{5bas^2}{t} \quad (\text{bytes / 层})$$

同一套全局激活的三类存储归属  $t = 2$  示意



**维度**  $b$ : micro-batch;  $s$ : 序列长度;  $h$ : hidden;  $a$ : 头数;  $t$ : TP 度。

**对象**  $X, H$  表示浮点激活,  $P$  表示注意力概率; 系数汇总多份激活与 mask 的字节数。

**机制** 箭头表示存储归属, 三行共同组成总显存; 图示省略 batch, 取  $a = t = 2$ 。

$H$  以宽度  $h$  为例; MLP 的  $4h$  中间态同样分为每卡  $4h/t$ 。