


$$M_{\text{TP}} = 10sbh + \frac{24sbh}{t} + \frac{5bas^2}{t}$$

$$M_{\text{TP+SP}} = \frac{10sbh}{t} + \frac{24sbh}{t} + \frac{5bas^2}{t} \quad (\text{bytes / 卡 / 层})$$

TP: 保留完整副本

TP+SP: 只保留序列分片

GEMM: 临时恢复完整输入



$$X_r = X[:, \mathcal{I}_r, :], \quad X = \text{concat}_s(X_0, X_1)$$

虚线框: 用完即可释放

维度 b : micro-batch; s : 序列长度; h : hidden; a : 头数; t : TP 度。图取 $t = 2$, 省略 b 。

对象 X 是 LayerNorm 后的浮点输入, X_r 保留完整 h ; $\mathcal{I}_r$ 是第 r 卡的序列区间, 彼此不重叠且覆盖全序列。

机制 虚线箭头比较保存方式, 实线表示通信; 两行是同一组内的两张卡。 M 汇总为反向保留的多份激活与 mask, 不含临时缓冲峰值; 图形表示逻辑形状。