



$$S_{ij} = Q_i K_j^\top / \sqrt{d}, \quad \tilde{P}_{ij} = \exp(S_{ij} - m_i^{\text{new}})$$

(1) 局部分数：沿 d 收缩；输入块由 HBM 搬入片上



(2) 加权累积：沿 B_c 收缩；沿用上排生成的权重



继续下一个 j : 保留 (m_i, ℓ_i, U_i) , 复用 Q_i , 载入下一块 K_j, V_j

所有 K/V 块处理完 $\rightarrow O_i = U_i / \ell_i \rightarrow$ 写回 HBM

轴 B_r : query 块行数; B_c : key/value 块行数; d : 单头特征维。格数仅示意轴结构。

对象 S 是分数, $\tilde{P}$ 是非负未归一化权重; U 是加权分子, 尚未除以分母。

片上 $S_{ij}, \tilde{P}_{ij}$ 用完即丢弃; (m_i, ℓ_i, U_i) 跨块累积。图示 FA-2 风格扫描。