



$$H = \phi(X[W_1^{(0)}|W_1^{(1)}]) = [H^{(0)}|H^{(1)}]$$

$$Y = [H^{(0)}|H^{(1)}] \begin{bmatrix} W_2^{(0)} \\ W_2^{(1)} \end{bmatrix} = P^{(0)} + P^{(1)}, \quad P^{(r)} = H^{(r)}W_2^{(r)}$$


SP 区域：同一 TP 组内，每卡负责一半 token，保留完整隐藏维



TP 区域：两卡执行同一条路径，但使用各自的权重分片 ($r = 0, 1$)



两张卡的部分和送入 ReduceScatter，回到 SP 区域



$$Y_i = (P^{(0)} + P^{(1)})[T_i, :] : \text{接下来本地做 Dropout、残差与下一次 LayerNorm}$$

维度 L : 序列长度; d : 隐藏维; f : MLP 中间维。省略 batch、bias; ϕ 为逐元素激活。

对象 X_i 是 LayerNorm 后的序列片段; $H^{(r)}$ 是通道片段; $P^{(r)}$ 是实值部分和，并非 Y 的切片。

机制 SP 与 TP 复用同两张卡。LayerNorm 只需单个 token 的完整 d ; TP 矩阵乘法需要各卡的权重分片。