


$$S_{ij} = Q_i K_j^T / \sqrt{d_h}, \quad O_i = \text{softmax}_{\text{all keys}}([S_{i0} | \cdots | S_{i,P-1}]) V$$

固定一张卡、一个 head: Q_i 留在本地, 每轮处理一个 KV 块



维度 $n = L/P$: 本地 token 数; d_h : head 维度。图中省略 batch 与 head 轴。

对象 S_{ij} 是分数; m_i, l_i 是逐行最大值、指数和; A_i 是未归一化加权。

机制 每轮重标定旧状态, 再合并新块; 不是把各块 softmax 的输出直接相加。图示无 mask。