


$$X_{i,j} = X[\mathcal{T}_i, \mathcal{H}_j, :] \xrightarrow{\text{All-to-All}} X^{(j)} = \text{concat}_{i, \text{seq}} X_{i,j}$$

通信前：每卡一段序列，全部 heads

通信后：每卡全部序列，一组 heads



维度 L : 序列长度; h : head 数; d_h : 每个 head 的通道数, $d = hd_h$ 。

对象 X 表示 Q、K 或 V 中任一实值张量; 颜色标记目标 head 组。

机制 图示 MHA、 $P = 2$, 省略 batch; 合并末两轴画矩阵面。交换数据归属, 不改变每卡元素数。