

$$q_{X,b,j} = Q_{\text{E4M3}}(X_{b,j}/s_{X,b}), \quad \hat{X}_{b,j} = s_{X,b}q_{X,b,j}, \quad X \in \{K, V\}, \quad 0 \leq j < 32$$

## 启动配置

--kv-cache-dtype mxfp8

KV 元素 E4M3 + 块 scale E8M0


--attention-backend fa4

读取块缩放 Q/K/V


--page-size 128

每页 128 个 token

写入：新 token 的一个 head,  $X = K$  或  $V$



读取：FA4 attention



轴  $d_X$  是一个 head 的 K 或 V 最后一维；每 32 个连续值对应一个 scale。128 是页内 token 数。

对象  $q_{X,b,j}$  是 FP8 数据， $s_{X,b}$  是正的 E8M0 scale； $Q$  为当前计算输入，K/V 来自缓存。

机制 128-token 页使 scale 采用 FA4 的交错布局； $QK^T$  用块缩放计算， $V$  在 kernel 内还原后参与  $PV$ 。