


$$\text{Attn}_M(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d_h} + B_M) V$$

$$M_{ij} = 1 \Rightarrow (B_M)_{ij} = 0 ; \quad M_{ij} = 0 \Rightarrow (B_M)_{ij} = -\infty$$

训练：当前帧、未来视频、动作

推理：当前帧、动作

Query：谁在读取




M_{train}

$(N_0 + N_f + H) \times (N_0 + N_f + H)$

删除 F 的行与列
保留相同的信息依赖



C 编码一次，缓存各层 K/V
 A 去噪时重复读取缓存



M_{infer}

$(N_0 + H) \times (N_0 + H)$

轴 横轴为 Key（被读取者），纵轴为 Query； N_0 、 N_f 、 H 为三组 token 数。

对象 C ：干净当前帧； F ：加噪未来视频； A ：加噪动作。彩色格为允许，白格为禁止。

机制 A 只读 C 与 A ， C 不读 F 或 A ；格数仅示意，省略条件注意力。