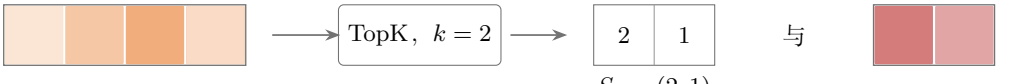
$$y_0 = 0.6\, f_2(x_0) + 0.4\, f_1(x_0)$$

EP=2：GPU 0 持有专家 0、1；GPU 1 持有专家 2、3。只跟踪源 GPU 0 的一个 token。

1. 路由先给出专家 ID 与权重：两个槽位对应两次专家计算



$s_0 = (0.1, 0.4, 0.6, 0.2)$

$[1, E]$，$E = 4$：连续路由分数

$S_0 = (2, 1)$

$[1, k]$：整数专家 ID

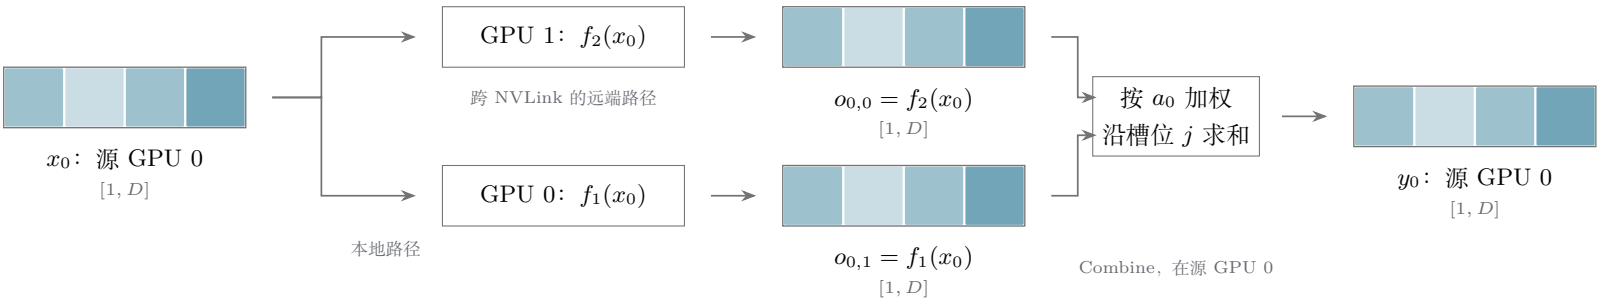
$a_0 = (0.6, 0.4)$

$[1, k]$：浮点权重

槽位 0：专家 2，位于 GPU 1

槽位 1：专家 1，位于 GPU 0

2. Dispatch 复制完整 token 行；专家输出回到源 GPU，沿所选专家槽位求和



x_0：源 GPU 0

$[1, D]$

跨 NVLink 的远端路径

本地路径

$o_{0,0} = f_2(x_0)$

$[1, D]$

$o_{0,1} = f_1(x_0)$

$[1, D]$

Combine，在源 GPU 0

y_0：源 GPU 0

$[1, D]$

维度　D 是完整 hidden 维度；E 是总专家数；k 是每 token 所选专家数。图中每个 token 向量等宽。

对象　S_0 是整数 ID 列表，a_0 是浮点权重；槽位 $j = 0, 1$ 表示选中的第几个专家。

机制　输入复制给选中专家，权重留在专家所在 GPU；输出按源 token 地址回传并合并。图展示逻辑语义。