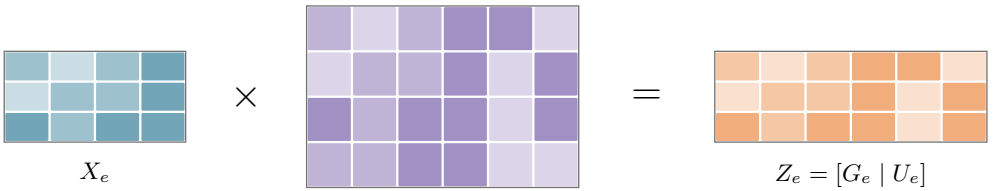
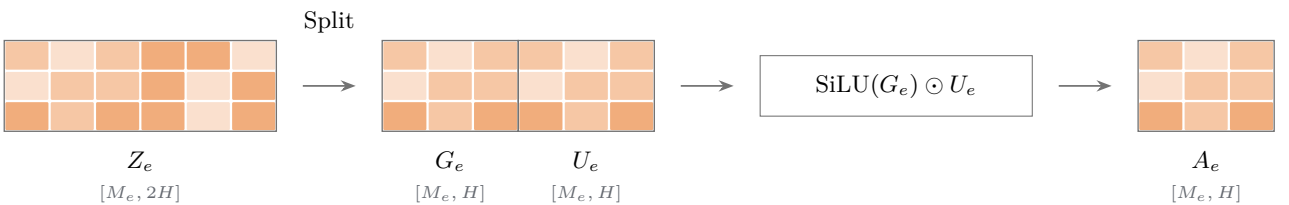
$$[G_e \mid U_e] = X_e W_{1,e}, \qquad O_e = (\mathrm{SiLU}(G_e) \odot U_e) W_{2,e}$$

1. Linear 1：收缩 D，一次得到 gate 与 up 两组通道

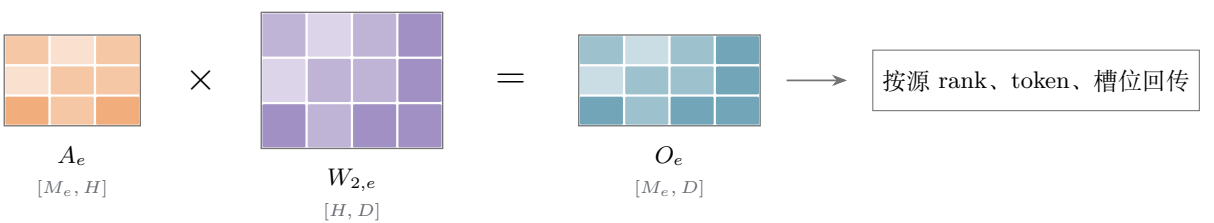


权重保持在专家所在 GPU。
M_e 随路由变化。

2. Split + SwiGLU：沿通道拆成两半，同位置逐元素运算



3. Linear 2：收缩 H，还原完整 hidden 维度，再回传源 token 的输出



维度 M_e 为专家 e 收到的 token 行数；D 为 hidden 宽度；H 为专家中间宽度。格子只示意轴结构。

对象 X_e, Z_e, A_e, O_e 是浮点张量；$W_{1,e}, W_{2,e}$ 是同一个本地专家的完整权重。

机制 $[M_e, D][D, 2H] \to [M_e, 2H]$；$[M_e, H][H, D] \to [M_e, D]$。同形状矩阵保持同尺寸。