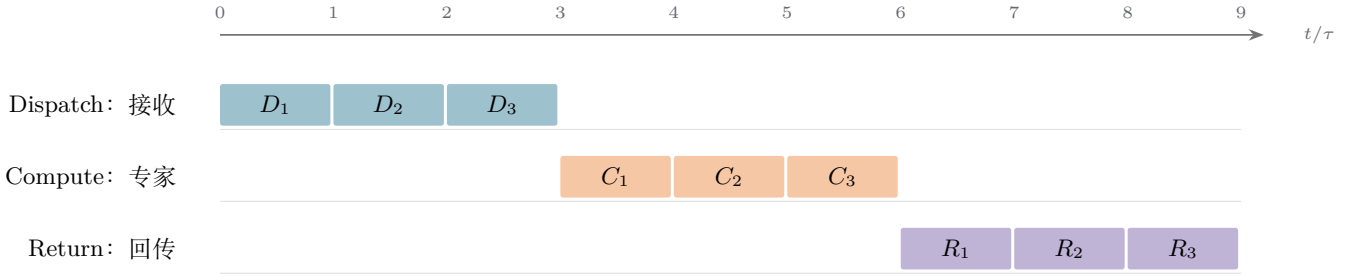
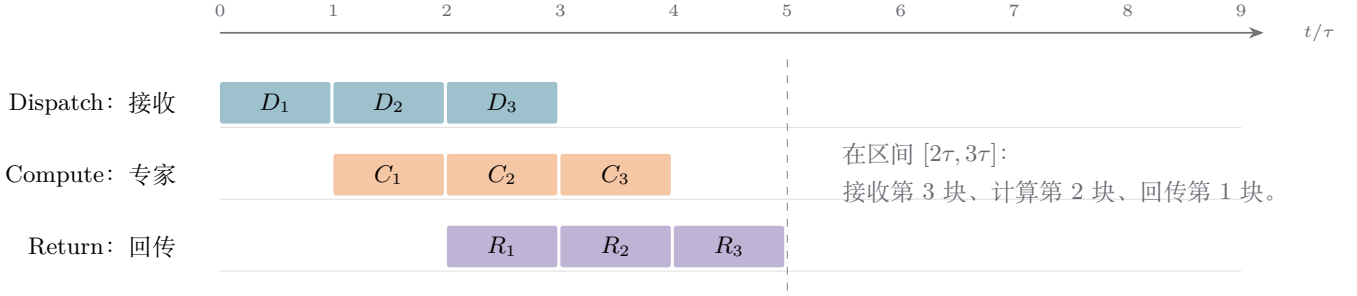
$$T_{\text{serial}} = 9\tau, \qquad T_{\text{pipeline}} = 5\tau \quad \text{（三块、三阶段的理想例子）}$$

每块依赖保持为 $D_i \to C_i \to R_i$；跨块重叠，不改变单块的先后关系。

1. 分阶段执行：整批 Dispatch 完成后计算，整批计算完成后回传



2. MegaMoE 的流水线思想：一块到齐就计算，一块算好就回传



维度 横轴是时间；$i = 1, 2, 3$ 是 token 数据块编号。三个阶段各假设每块耗时 τ。

对象 D_i 接收输入；C_i 包含两次 GEMM 与 SwiGLU；R_i 回传贡献。颜色表示工作类型。

机制 这是理想教学时间线，不是 profiler 记录。实际存在启动、同步、归并和资源竞争，阶段耗时也不同。