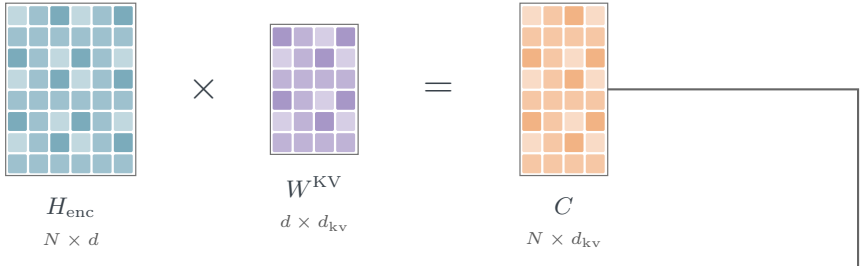
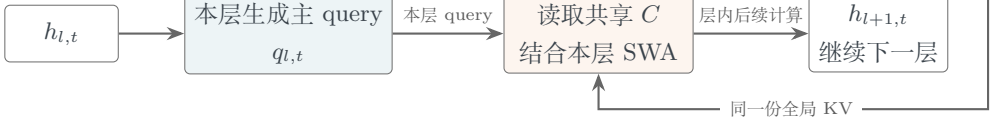
$$H_{\text{enc}} W^{\text{KV}} = C$$

长提示词经过 causal encoder，输出直接建立 decoder 全局记忆



处理当前 token 时，各 decoder 层仍逐层计算



维度　N 为历史 token 数，d 为隐藏维度，d_{kv} 为 KV 维度；格数仅示意轴结构。

边界　图示 decoder 的 $m = 1$ 全局路径，省略归一化、RoPE 等步骤。

局部　长输入仍需末尾短窗口重放以建立逐层 SWA；新 token 的 decode 仍经过两半网络。