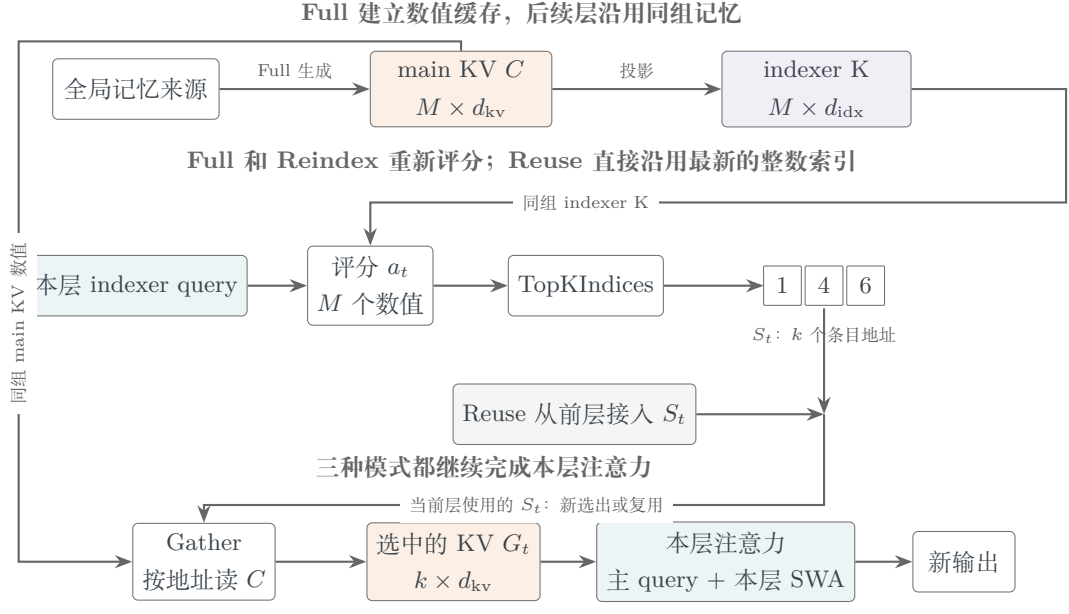
$$S_t = \mathrm{TopKIndices}_k(a_t), \qquad G_t[j,:] = C[S_{t,j},:]$$



对象 C、indexer K、a_t 是数值；S_t 是整数地址。槽位中的 1、4、6 仅作示意。

共享 Full 新建缓存并检索；Reindex 复用缓存但重选 S_t；Reuse 复用缓存和最新 S_t。

范围 Decoder 的后续 Reindex 只在首个 Full 构建的候选池中评分；各层仍生成新表示。