异步调度：旧信息决定做多少，新信息决定分给谁

统一以调度第 N 步编号：进入第 N 步前，总预算已经固定，GPU 只重分配逐请求长度。

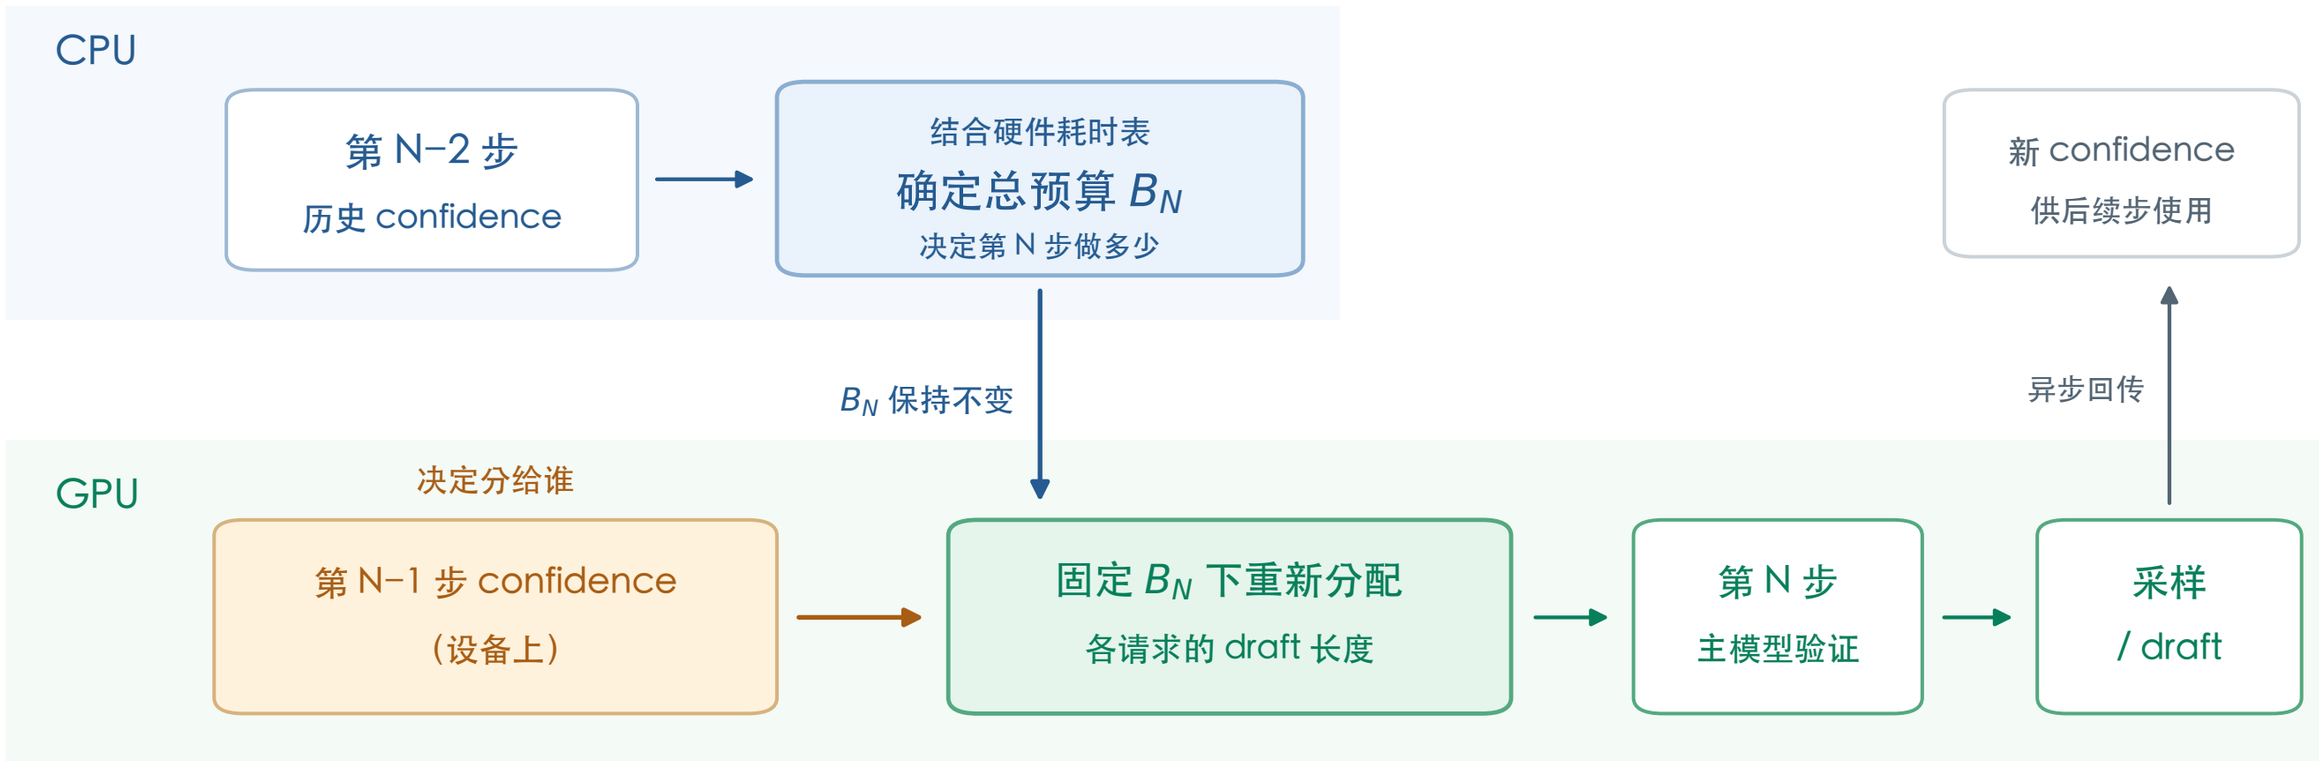

两条信息路径：N−2 → 总预算 B_N；N−1 → 固定 B_N 下的逐请求分配。

图为逻辑依赖示意；框宽、间距和箭头长度均不代表耗时。