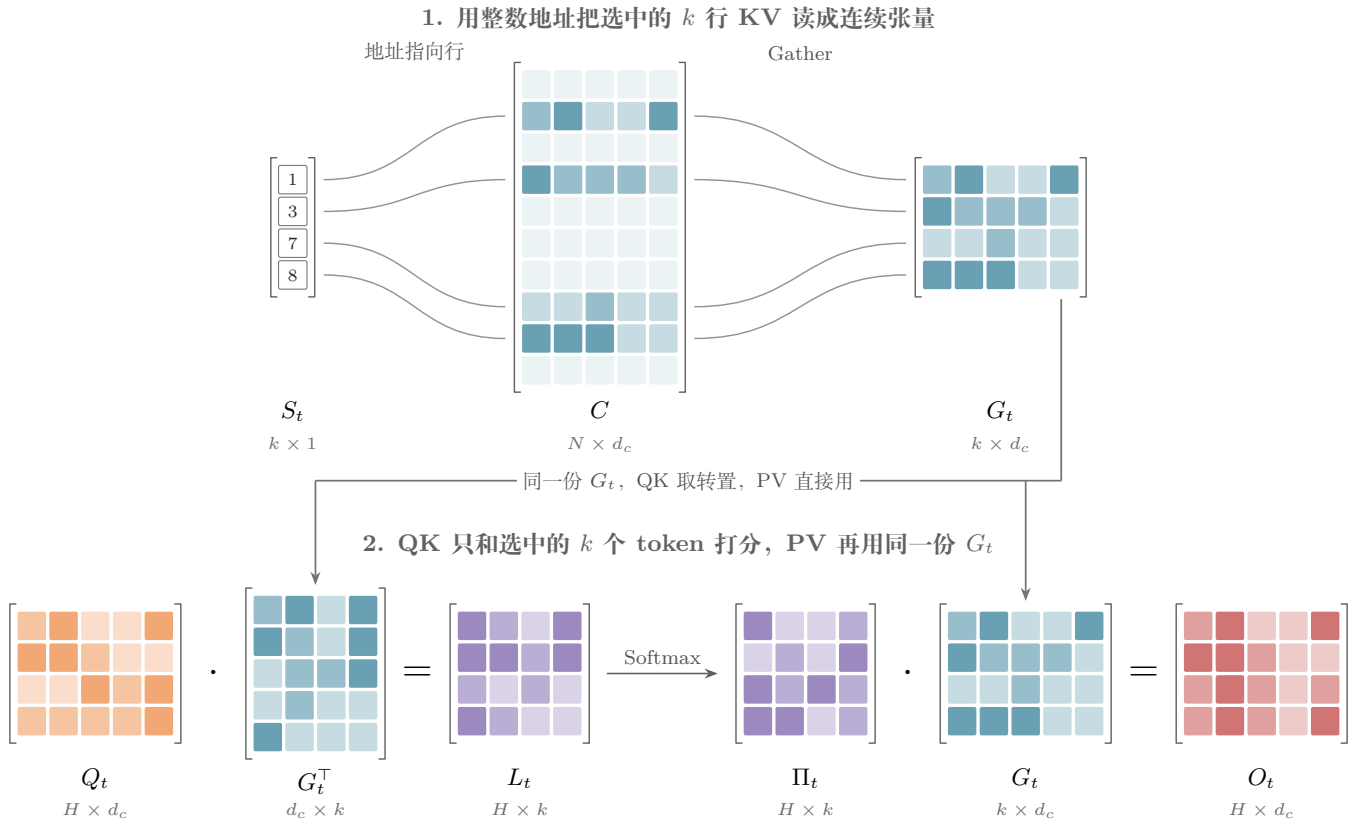
$$G_t[r,:] = C\big[S_t[r],:\big], \qquad O_t = \mathrm{Softmax}\big(Q_t G_t^\top\big)\, G_t$$




**轴** $N$ 是上下文长度；$r \in \{0, \ldots, k-1\}$ 是选中槽位；$H$ 是主注意力的 query head 数；$d_c$ 是 KV 的 latent 维度。

**对象** $C$ 是所有 head 共享的 KV，浅色行本次不读取；$S_t$ 是整数地址；$L_t$ 是 logits；$\Pi_t$ 每行和为 1；$O_t$ 是各 head 的输出。

**机制** Gather 后 $N$ 轴换成 $k$ 轴，这一步不再随 $N$ 增长；所有 head 共用一份 $G_t$。V3.2：$H$=128，$k$=2048，QK 用 576 维，PV 用其中不含 RoPE 的 512 维。