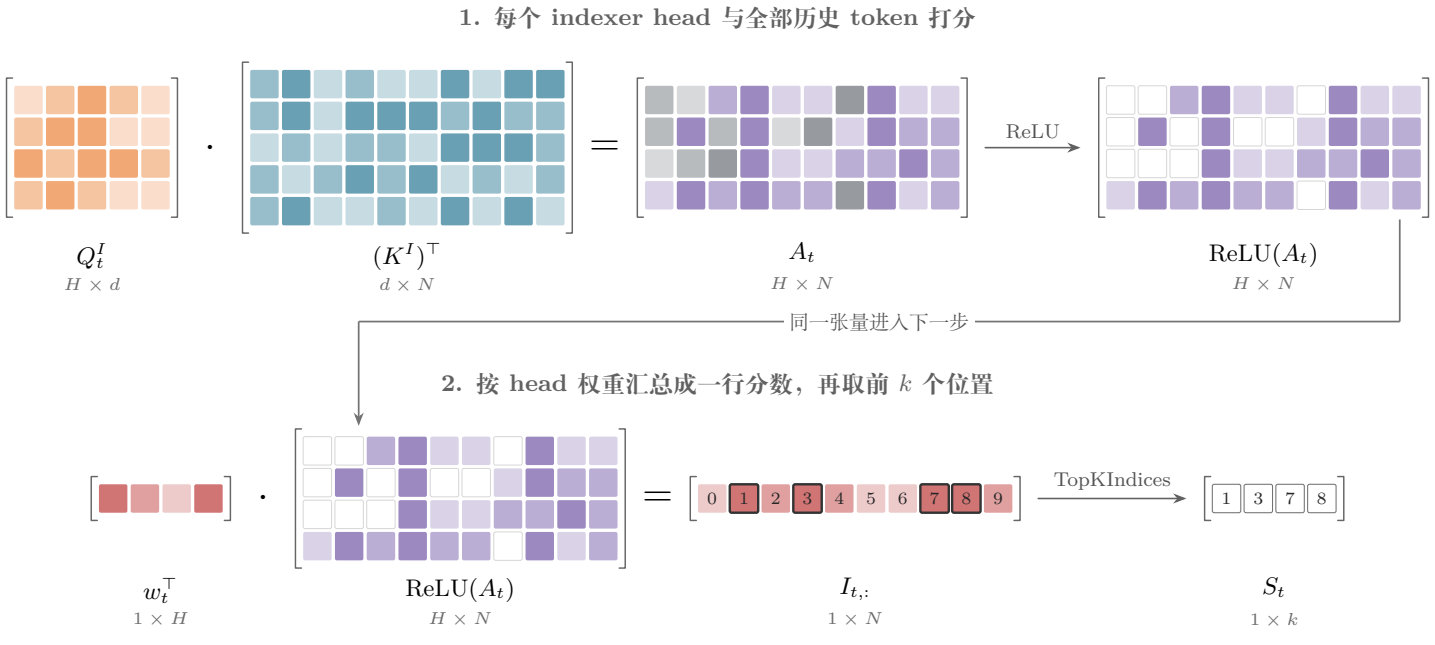
$$I_{t,s} = \sum_{j=1}^{H} w_{t,j}\,\mathrm{ReLU}\left(q_{t,j}^{\top} k_s\right), \qquad S_t = \mathrm{TopKIndices}(I_{t,:},\, k)$$



轴 t 是当前 query；j 是 indexer head，共 H 个；$s \in \{0, \ldots, N-1\}$ 是历史 token 位置；d 是 indexer 维度。

对象 A_t 是带符号打分，灰色为负，经 ReLU 后为 0（留白）；$I_{t,:}$ 是实数分数，格内数字是位置 s；S_t 是升序的整数地址，不是 mask。

机制 $(H \times d)(d \times N) \to H \times N$，$(1 \times H)(H \times N) \to 1 \times N$。V3.2 的配置是 H=64，d=128，k=2048。格数只示意轴结构。