$$\left|R_t^{\mathrm{NSA}}\right| = \lfloor N/d \rfloor + n\,l' + w, \qquad \left|R_t^{\mathrm{DSA}}\right| = k \ \ (\text{另扫}N\text{ 个 index key})$$

NSA：压缩分支做真实注意力，顺带给块打分，再读整块和末尾窗口



DSA：indexer 只负责打分，主注意力只读选中的 k 个 token



轴　N 是上下文长度；d 是压缩步长；l' 是选择块大小，n 是选中的块数；w 是滑窗长度；k 是 DSA 选中的 token 数。

对象　p_t^{cmp} 和 $I_{t,:}$ 是实数分数，黑框为选中项；R_t 是主注意力读取的布尔掩码，橙色是选中的 token，蓝色是滑窗，留白表示不读。

机制　NSA 的读取是连续块，但粗路径也要读 $\lfloor N/d \rfloor$ 个压缩 token；DSA 的读取分散，粗路径只读更小的 index key。论文配置：NSA 为 d=16, l'=64, n=16, w=512，V3.2 为 k=2048。格数只示意。